

Progressive 2× 超分辨的物理推导

面向物理 PhD 的版本：从采样定理、Zel'dovich 和 2LPT 一路算到 flow matching

为张潇文准备

2026 年 9 月 8 日 (v2, 审阅后修订)

读法

这份笔记和上一份的内容相同，但写法不同：不设定理，每一步都是”把这个代进去、展开、看极限”，先一维再三维，公式旁边给物理解释。需要的数学只有：Fourier 级数与几何级数求和、高斯随机场与功率谱 ($\langle \hat{\delta} \hat{\delta}^* \rangle$)、Wick)、Zel'dovich 与 2LPT、条件期望和 tower property $\mathbb{E}[\mathbb{E}[X | Y]] = \mathbb{E}[X]$ 、以及一阶常微分方程。标着”自己算”的地方是建议你亲手做一遍的。

全文的记号：盒长 L ，周期边界。粗网格 (coarse, 下标 c) 每维 N 个点、格距 $h_c = L/N$ ；细网格 (fine, 下标 f) 每维 $2N$ 个点、格距 $h_f = h_c/2$ 。格点位置 $q_j = (j + o)h$, $o \in \{0, \frac{1}{2}\}$ 是初条件生成器的网格约定。位移场 $\Psi(\mathbf{q})$ 定义在初始网格上，粒子现在的位置是 $\mathbf{x} = \mathbf{q} + \Psi(\mathbf{q})$ 。

1 一维热身：采样、aliasing、粗细网格

1.1 环上的 Fourier 级数

长度为 L 的环上的函数 $g(x)$ 展开为

$$g(x) = \frac{1}{L} \sum_{m \in \mathbb{Z}} \hat{g}_m e^{ik_m x}, \quad k_m = \frac{2\pi m}{L}, \quad \hat{g}_m = \int_0^L g(x) e^{-ik_m x} dx. \quad (1)$$

两个函数的乘积在 Fourier 空间是卷积，带一个 $1/L$: $\widehat{(g_1 g_2)}_m = \frac{1}{L} \sum_{m_1 + m_2 = m} \hat{g}_{1, m_1} \hat{g}_{2, m_2}$ (把两个级数相乘、合并指数即可)。对一个统计均匀的随机场， $\langle \hat{g}_m \hat{g}_{m'}^* \rangle = L P(k_m) \delta_{mm'}$ 定义功率谱；三维时把 L 换成 L^3 。

1.2 采样与几何级数：aliasing 公式

在 N 个点 $x_j = (j + o)h$ ($h = L/N$) 上采样，并按 `numpy.fft` 的约定做离散变换，注意相位是对整数指标 j 而不是对物理位置 x_j 取的：

$$G_m := \sum_{j=0}^{N-1} g(x_j) e^{-ik_m j h}. \quad (2)$$

把 (1) 代进去：

$$G_m = \frac{1}{L} \sum_{m'} \hat{g}_{m'} e^{ik_{m'}oh} \sum_{j=0}^{N-1} e^{i(k_{m'}-k_m)jh}. \quad (3)$$

里面那个和是几何级数。因为 $(k_{m'} - k_m)h = 2\pi(m' - m)/N$,

$$\sum_{j=0}^{N-1} e^{2\pi i(m'-m)j/N} = \begin{cases} N, & m' - m \in N\mathbb{Z}, \\ 0, & \text{否则}. \end{cases} \quad (4)$$

于是

$$G_m = \frac{N}{L} \sum_{n \in \mathbb{Z}} \hat{g}_{m+nN} e^{ik_{m+nN}oh} \quad (5)$$

这就是 aliasing：第 $m + nN$ 个模式在采样后和第 m 个模式无法区分，它们相差的波数 $nNk_1 = 2n\pi/h$ 恰好是 Nyquist 波数 $k_{\text{Ny}} = \pi/h$ 的偶数倍。

采样定理。 如果 g 是带限的，即 $\hat{g}_{m'} = 0$ 当 $|m'| \geq N/2$ ，那么 (5) 里只剩 $n = 0$ ：

$$G_m = \frac{1}{h} e^{ik_moh} \hat{g}_m, \quad |m| < N/2. \quad (6)$$

采样没有丢任何信息，反过来可以精确重建 $g(x) = \frac{h}{L} \sum_{|m| < N/2} G_m e^{-ik_moh} e^{ik_mx}$ 。这就是“带限函数由 Nyquist 频率以上的采样完全决定”。 N 是偶数时 $m = \pm N/2$ 这个 Nyquist 模式只能被表示成一个实的余弦，为了不处理这个特例，我们规定带限的意思是 $|m| < N/2$ 严格成立，代码里把 Nyquist 平面直接置零。

1.3 两套网格看同一个带限函数

设 g 对粗网格是带限的 ($|m| < N/2$)，它当然也对细网格带限。对两套网格分别用 (6)：

$$G_m^c = \frac{1}{h_c} e^{ik_moh_c} \hat{g}_m, \quad G_m^f = \frac{1}{h_f} e^{ik_moh_f} \hat{g}_m \implies \boxed{G_m^c = \frac{h_f}{h_c} e^{ik_m o(h_c - h_f)} G_m^f = \frac{1}{2} e^{ik_moh_f} G_m^f} \quad (7)$$

读法：把细网格的 DFT 系数原样搬到粗网格的 DFT 数组里（细网格多出来的高频槽位扔掉），乘 $\frac{1}{2}$ ，再乘一个相位 $e^{ik_moh_f}$ 。 $o = 0$ 时相位是 1，因为粗格点是细格点的子集； $o = \frac{1}{2}$ 时粗格点在两个细格点正中间，差半个细格，这个相位就是那半个细格的平移。三维时因子是 $\frac{1}{8}$ ，相位是 $e^{i\mathbf{k} \cdot \mathbf{1} oh_f}$ ，因为每一维各出一个因子。这就是代码里 `restrict_spectral` 的 $(N_c/N_f)**3$ 和 `conj(phase)`。

自己算：取单个模式 $g = e^{ikx}$ ， $o = \frac{1}{2}$ ，粗格点 $x_j^c = (2j+1)h_f$ ，直接写出 G^c 和 G^f 验证 (7)。

1.4 Restriction、prolongation 和投影

现在定义两个算子。 P (prolongation, 粗到细)：把粗网格 DFT 系数按 (7) 的逆搬到细网格数组里，其余槽位填零 (zero padding)，反变换得到细格点上的值。由采样定理，这就是“把粗网格

上的数看成一个带限函数，在细格点上精确插值”。 R (restriction, 细到粗)：细网格 DFT，只保留一个指示函数 $W_m \in \{0, 1\}$ 选中的模式 ($W_m = 1$ 的模式必须都在粗网格能表示的范围 $|m| < N/2$ 里)，按 (7) 搬到粗网格数组，反变换。

两条一行就能验证的性质：

$$RP = \text{恒等} \quad (\text{在 } W \text{ 选中的模式上})：\text{搬过去再搬回来，因子 } \frac{1}{2} \cdot 2、\text{相位 } e^{-i\cdots} e^{+i\cdots} \text{ 都抵消。} \quad (8)$$

$$PR = \mathcal{P}_W \quad (\text{在细网格上})：\text{保留 } W_m = 1 \text{ 的模式、杀掉其余，即 Fourier 乘子 } W_m。 \quad (9)$$

$\mathcal{P}_W$ 是投影，因为 $W_m^2 = W_m$ ；它是正交投影，因为 Parseval $\sum_j |g(x_j)|^2 = \frac{1}{N} \sum_m |G_m|^2$ 告诉我们不同模式正交。于是任何细场唯一地分成两块：

$$\Psi_f = \underbrace{P(R\Psi_f)}_{W \text{ 选中的模式, 粗网格能表示}} + \underbrace{(I - \mathcal{P}_W)\Psi_f}_{=: d, \text{ 细节: 其余模式}} \quad (10)$$

而且两块正交。 W 的两个选择：立方体 ($|k_j| < k_{\text{Ny},c}$ 对每个 j) 或球 ($|\mathbf{k}| < \alpha k_{\text{Ny},c}$, $\alpha \leq 1$)。默认用立方体：什么都不丢，链的状态就是粗数组本身，第 2 节的 nested IC 分解和模型的分解完全重合，后面关于“新随机性”的每一句话都是精确的。球的诱惑在于各向同性，而且粗立方体角落里那些 $|\mathbf{k}|$ 最大的模式 ($\alpha = 1$ 时占粗模式的 $1 - \pi/6 \approx 48\%$) 是低分辨率模拟分辨得最差的；但用球意味着先把输入投影一次 $\Psi_c \leftarrow \mathcal{P}_W \Psi_c$ ，再把角落当作新随机性重新生成——这是一个近似：角落模式 χ 在初条件里确实独立，但粗模拟球内的非线性输出 $\mathcal{P}_W \mathcal{S}_c[\delta_W + \chi]$ 通过模式耦合带着 χ 的信息， $p(\chi | \mathcal{P}_W \Psi_c) \neq p(\chi)$ 。精确的做法是把角落留在状态里、交给修正带去修。球应当作为一个对照实验，而不是理论基线。 W 必须是 0/1 的指示函数：换成平滑窗， $W^2 \neq W$ ， PR 就不是投影， $RP \neq I$ ，粗、细两块在过渡带里重叠。

有了这些，一个 $2\times$ 步骤的任务就清楚了。给定粗模拟 Ψ_c (用球时是投影过的)，定义

$$\varepsilon := R\Psi_f - \Psi_c \quad (\text{粗场修正}), \quad \Psi_f = P(\Psi_c + \varepsilon) + d. \quad (11)$$

ε 和 d 都是同一个细网格残差 $\Psi_f - P\Psi_c$ 的一部分： ε 是它 W 带内的部分， d 是带外的部分。所以模型只需要一个细网格上的输出，“两个头”只是同一个输出的两个频带。

1.5 对比：Haar (块平均) 为什么不好

Haar 把每两个相邻细格点取平均当作粗格点的值。取 $o = \frac{1}{2}$ ，粗点在块中心，对单个模式

$$\frac{1}{2} \left[e^{ik(x_c - h_f/2)} + e^{ik(x_c + h_f/2)} \right] = \cos\left(\frac{kh_f}{2}\right) e^{ikx_c}. \quad (12)$$

三维是三个 $\cos$ 的乘积。这说明两件事：本该原样保留的粗带模式被乘了 $\cos(kh_f/2) \approx 1 - (kh_f)^2/8$ ，是一个确定性的失配；细网格才有的高频模式经过 $\cos$ 衰减后仍然不为零（只在细 Nyquist 处为零），所以它们按 (5) 折叠回粗带，是一个随机的污染。 $o = 0$ 时块中心比粗点多偏半个细格，还额外多一个相位 $e^{ikh_f/2} \approx 1 + ikh_f/2$ ，失配从 $O(k^2)$ 变成 $O(k)$ 。后面会看到，谱型的 R 在线性阶根本没有这两项。

自己算：位移功率谱 $P_\Psi \propto k^{n-2}$ ($n = -1.5$) 时, *Haar* 的 ε 在低 k 的功率谱斜率, $o = \frac{1}{2}$ 是 $4 + (n - 2) = +0.5$, $o = 0$ 是 $2 + (n - 2) = -1.5$ 。自测量到 $+0.6$ 和 -1.7 。

2 高斯初条件、nested IC 与线性理论

2.1 高斯随机场的三句话

线性密度场 δ 是高斯随机场：每个 Fourier 系数 $\hat{\delta}(\mathbf{k})$ 是独立的复高斯变量（受实性条件 $\hat{\delta}(-\mathbf{k}) = \hat{\delta}(\mathbf{k})^*$ 约束）， $\langle \hat{\delta}(\mathbf{k}) \hat{\delta}^*(\mathbf{k}') \rangle = L^3 P_{\text{lin}}(k) \delta_{\mathbf{k}\mathbf{k}'}$ ，所有高阶矩由 Wick 定理决定。”独立”是关键词：不同 $\mathbf{k}$ 的系数之间没有任何统计关系。

2.2 Nested IC

初条件生成器对第 ℓ 级只生成 $|k_j| < k_{\text{Ny},\ell}$ 的模式，并且同一个 $\mathbf{k}$ 在所有级别用同一个随机数。所以

$$\delta_f = \delta_c + \eta, \quad \hat{\delta}_c = W_{\text{cube}} \hat{\delta}_f, \quad \hat{\eta} = (1 - W_{\text{cube}}) \hat{\delta}_f, \quad (13)$$

η （我叫它 octave）由细立方体减去粗立方体里的模式组成，是一批和 δ_c 完全独立的高斯随机数。每个分量数一数： $(2N)^3 - N^3 = 7N^3$ 个模式，正好等于每个粗格子里新增的 7 个细粒子。

2.3 Zel'dovich

线性阶的连续性方程加 Poisson 方程给出 $\Psi^{(1)} = -D \nabla \phi$, $\nabla^2 \phi = \delta$ (δ 归一到今天, D 是增长因子)。Fourier 空间：

$$\hat{\phi} = -\frac{\hat{\delta}}{k^2}, \quad \hat{\Psi}^{(1)}(\mathbf{k}) = D \frac{i\mathbf{k}}{k^2} \hat{\delta}(\mathbf{k}), \quad \nabla \cdot \Psi^{(1)} = -D \delta. \quad (14)$$

速度是 $\dot{D}$ 替换 D 。注意 $\hat{\Psi}^{(1)}(\mathbf{k})$ 只依赖同一个 $\mathbf{k}$ 的 $\hat{\delta}(\mathbf{k})$ ：Zel'dovich 是一个 Fourier 乘子，和任何谱投影可交换。

2.4 线性阶的两个结论

把 (14) 代进 (11) 和 (10)，逐模式看。对 W 选中的模式 $\mathbf{k}$ （它们都在粗立方体里）：

$$(R\Psi_f^{(1)})(\mathbf{k}) = D \frac{i\mathbf{k}}{k^2} \hat{\delta}_f(\mathbf{k}) = D \frac{i\mathbf{k}}{k^2} \hat{\delta}_c(\mathbf{k}) = (P_W \Psi_c^{(1)})(\mathbf{k}) \implies \varepsilon^{(1)} \equiv 0. \quad (15)$$

对 W 之外的模式：

$$\hat{\delta}^{(1)}(\mathbf{k}) = D \frac{i\mathbf{k}}{k^2} \hat{\delta}_f(\mathbf{k}), \quad \text{只含 octave 的模式 (若 } W \text{ 是球, 再加粗立方体的角落)}. \quad (16)$$

所以在线性阶，粗场修正精确为零，细节是一个功率谱已知 ($D^2 P_{\text{lin}}/k^2$, 纵向) 的高斯场，并且与粗场统计独立，因为它们用的是不相交的两组独立高斯数。

这两句话决定了模型的两个设计：线性阶的细节应该直接写进模型而不是让网络学（模型的”起点”已经包含 $D i\mathbf{k}\hat{\eta}/k^2$ ）；网络注入的随机数应该就是 octave 的初条件 η 本身，而不是无名的噪声。

3 二阶：粗场修正为什么小，细节怎么依赖粗场

3.1 2LPT 回顾

你推过的结果 (Bouchet 等 1995 的约定), $D = 1$:

$$\Psi = -\nabla\phi^{(1)} + D_2\nabla\phi^{(2)}, \quad D_2 \simeq -\frac{3}{7}, \quad \nabla^2\phi^{(2)} = S := \sum_{i>j} \left[\phi_{,ii}^{(1)}\phi_{,jj}^{(1)} - (\phi_{,ij}^{(1)})^2 \right]. \quad (17)$$

把 S 写成更好用的形式 (展开 $(\sum_i \phi_{,ii})^2$ 和 $\phi_{,ij}\phi_{,ij}$, 对角项抵消):

$$S = \frac{1}{2} \left[(\nabla^2\phi)^2 - \phi_{,ij}\phi_{,ij} \right] = \lambda_1\lambda_2 + \lambda_2\lambda_3 + \lambda_3\lambda_1, \quad (18)$$

λ_i 是 $\phi_{,ij}$ 的本征值。以后省略上标 (1)。二阶位移是 S 的势的梯度。注意 ∇^{-2} 的 Fourier 乘子是 $-1/k^2$, 所以实空间和 Fourier 空间的写法差一个符号:

$$\Psi^{(2)} = D_2\nabla\nabla^{-2}S = -\frac{3}{7}\nabla\nabla^{-2}S, \quad \hat{\Psi}^{(2)}(\mathbf{k}) = D_2 i\mathbf{k} \hat{\phi}^{(2)} = -D_2 \frac{i\mathbf{k}}{k^2} \hat{S}(\mathbf{k}) = +\frac{3}{7} \frac{i\mathbf{k}}{k^2} \hat{S}(\mathbf{k}). \quad (19)$$

(第一版笔记的实空间式子丢了这个负号。) 下面把”源项 $\rightarrow$ 二阶位移” 这个线性算子记作 $\mathcal{T}_2 := D_2\nabla\nabla^{-2}$ 。 S 的 Fourier 形式: 用 $\hat{\phi}_{,ij} = -k_i k_j \hat{\phi} = k_i k_j \hat{\delta}/k^2$ 和卷积公式,

$$\hat{S}(\mathbf{k}) = \frac{1}{2L^3} \sum_{\mathbf{k}_1+\mathbf{k}_2=\mathbf{k}} K(\mathbf{k}_1, \mathbf{k}_2) \hat{\delta}(\mathbf{k}_1) \hat{\delta}(\mathbf{k}_2), \quad K(\mathbf{k}_1, \mathbf{k}_2) = 1 - \frac{(\mathbf{k}_1 \cdot \mathbf{k}_2)^2}{k_1^2 k_2^2}. \quad (20)$$

3.2 长短波分解

写 $\delta_f = \delta_L + \eta$, $\delta_L = \delta_c$ 。 S 是 ϕ 的二次型, 代入 $\phi = \phi_L + \phi_\eta$ 展开平方:

$$S[\delta_L + \eta] = S[\delta_L] + S[\eta] + B(\delta_L, \eta), \quad B(\delta_L, \eta) = \nabla^2\phi_L \nabla^2\phi_\eta - \phi_{L,ij}\phi_{\eta,ij}. \quad (21)$$

($\frac{1}{2}[(a+b)^2 - (A+B)_{ij}(A+B)_{ij}]$ 的交叉项, $\frac{1}{2}$ 被 2 抵消。) 粗模拟如果对带限输入 δ_L 精确求解连续方程, 会给出 $\Psi_c^{(2)} = \mathcal{T}_2 S[\delta_L]$; 细模拟给出 $\Psi_f^{(2)} = \mathcal{T}_2 [S[\delta_L] + B + S[\eta]]$ 。 分别用 $\mathcal{P}_W$ 和 $I - \mathcal{P}_W$ 投影:

$$\boxed{\varepsilon^{(2)} = \mathcal{P}_W \mathcal{T}_2 [B(\delta_L, \eta) + S[\eta]], \quad d^{(2)} = (I - \mathcal{P}_W) \mathcal{T}_2 [S[\delta_L] + B(\delta_L, \eta) + S[\eta]]} \quad (22)$$

$S[\delta_L]$ 只在**修正**里抵消 (两个模拟在粗带里都有它), 在**细节**里并不消失: 两个粗带模式可以相加成一个粗带之外的模式。举个具体例子, 以 k_F 为单位、粗截止为 4: $\mathbf{p} = (3, 2, 0)$ 和 $\mathbf{q} = (3, -2, 0)$ 都在粗立方体里, $\mathbf{p} + \mathbf{q} = (6, 0, 0)$ 在粗立方体外、细立方体内, 而 $K(\mathbf{p}, \mathbf{q}) = 1 - 25/169 = 144/169 \neq 0$ 。所以哪怕 $\eta \equiv 0$, 细节也不为零。这意味着细节里有一部分是粗初条件的确定性函数 (粗模式的非线性”谐波”), 另一部分才由 octave 驱动; 模型既然以粗场为条件, 两部分它都会产出, 但”细节就是新注入的随机性”这句话只在线性阶成立。剩下两项: $S[\eta]$ 是”小尺度对大尺度的反作用”, B 是长短波耦合。

3.3 S 是一个二阶散度： k^2 定律的物理来源

这是整份笔记里最值得亲手算的一段。用乘积法则把 S 写成全导数：

$$\partial_i [\phi_{,i} \phi_{,jj} - \phi_{,j} \phi_{,ij}] = \phi_{,ii} \phi_{,jj} + \phi_{,i} \phi_{,jji} - \phi_{,ij} \phi_{,ij} - \phi_{,j} \phi_{,iij}. \quad (23)$$

后两项 $\phi_{,i} \partial_i (\nabla^2 \phi)$ 和 $\phi_{,j} \partial_j (\nabla^2 \phi)$ 是同一个东西（哑指标），抵消。所以

$$S = \partial_i J_i, \quad J_i = \frac{1}{2} [\phi_{,i} \nabla^2 \phi - \phi_{,j} \phi_{,ij}]. \quad (24)$$

再来一次。 $\phi_{,j} \phi_{,ij} = \frac{1}{2} \partial_i (\phi_{,j} \phi_{,j})$ ，而 $\phi_{,i} \nabla^2 \phi = \partial_j (\phi_{,i} \phi_{,j}) - \phi_{,ij} \phi_{,j} = \partial_j (\phi_{,i} \phi_{,j}) - \frac{1}{2} \partial_i (\phi_{,j} \phi_{,j})$ 。代回去：

$$J_i = \partial_j T_{ij}, \quad \boxed{S = \partial_i \partial_j T_{ij}, \quad T_{ij} = \frac{1}{2} (\phi_{,i} \phi_{,j} - \delta_{ij} |\nabla \phi|^2)}. \quad (25)$$

二阶的源项是一个由引力场 $\nabla \phi$ 构成的”应力张量”的二阶散度——和牛顿引力的 Maxwell 型应力张量是同一个结构。物理上这是动量守恒：一个区域内部的物质再怎么重新排列，对外的净作用只能通过边界上的应力传出去。

Fourier 变换 ($\partial_i \partial_j \rightarrow -k_i k_j$):

$$\hat{S}(\mathbf{k}) = -k_i k_j \hat{T}_{ij}(\mathbf{k}). \quad (26)$$

把 $\eta\eta$ 那一项单独拿出来看小 k 极限。对每一个实现， $\hat{S}_{\eta\eta}(\mathbf{k}) = -k_i k_j \hat{T}_{ij}^{\eta\eta}(\mathbf{k})$ ，其中 $\hat{T}_{ij}^{\eta\eta}(\mathbf{k})$ 是两个 octave 模式的卷积，在 $k \ll k_{\text{Ny},c}$ 时是一个方差与 k 无关的随机变量（它的均值是各向同性常数， $\mathbf{k} = 0$ 处就是小尺度场应力在整个盒子上的积分）。于是

$$\hat{S}_{\eta\eta}(\mathbf{k}) = -k_i k_j \hat{T}_{ij}^{\eta\eta} = O(k^2), \quad \hat{\Psi}_{\eta\eta}^{(2)} = \frac{3}{7} \frac{i\mathbf{k}}{k^2} \hat{S}_{\eta\eta} = -\frac{3}{7} i\mathbf{k} \hat{k}_i \hat{k}_j \hat{T}_{ij}^{\eta\eta} = O(k). \quad (27)$$

把” $O(k^2)$ ”说成功率谱的语言要用 Wick 定理： $\hat{S} = \frac{1}{2} \int K \hat{\eta} \hat{\eta}$ 的两点函数有两个收缩、核对称，所以

$$\begin{aligned} P_{S_{\eta\eta}}(k) &= \frac{1}{2} \int \frac{d^3 p}{(2\pi)^3} K^2(\mathbf{p}, \mathbf{k} - \mathbf{p}) P_{\eta}(p) P_{\eta}(|\mathbf{k} - \mathbf{p}|) \\ &= k^4 \cdot \frac{1}{2} \int \frac{d^3 p}{(2\pi)^3} \frac{(1 - \mu_p^2)^2}{|\mathbf{k} - \mathbf{p}|^4} P_{\eta}(p) P_{\eta}(|\mathbf{k} - \mathbf{p}|) \rightarrow C k^4, \end{aligned} \quad (28)$$

第二个等号用了下面的精确恒等式 (30)，剩下的积分在远离原点的一个频带上、收敛到常数 C 。再记 $\vartheta := -\nabla \cdot \Psi$ 为位移的散度（注意：它不是完整的二阶 Eulerian 密度，见下面的说明）， $\hat{\vartheta}^{(2)} = \frac{3}{7} \hat{S}$ ，就得到

$$\boxed{P_{\Psi_{\eta\eta}^{(2)}}(k) = \left(\frac{3}{7}\right)^2 \frac{P_{S_{\eta\eta}}}{k^2} \propto k^2, \quad P_{\vartheta_{\eta\eta}^{(2)}}(k) = \left(\frac{3}{7}\right)^2 P_{S_{\eta\eta}} \propto k^4, \quad k \ll k_{\text{Ny},c}.} \quad (29)$$

这就是 Peebles 的 k^4 尾巴，在 Lagrangian 语言里是”小尺度对大尺度的反作用被动量守恒压低”。自测在去 aliasing 的 2LPT 层级上量到球壳平均的斜率 2.19（位移）和 4.14（散度）。

三个限定。第一，混合项 $B(\delta_L, \eta)$ 带同样的核因子，但能相加成小 $\mathbf{k}$ 的 $(\mathbf{k}_L, \mathbf{k}_\eta)$ 对必须都落在截止面附近厚度 $\sim k$ 的壳层里，相空间也随 k 缩小，所以它的低 k 功率至少和 $\eta\eta$ 项一样陡；

低 k 修正由 $S[\eta]$ 主导。第二，这是理想的、去 aliasing 的二阶结果；更高阶的确定性响应和真实粗模拟的离散性误差不必共享这个指数。第三，散度 ϑ 和 Eulerian 密度是两个场。质量守恒给出 $\hat{\delta}_E(\mathbf{k}) = \int d^3q e^{-i\mathbf{k}\cdot\mathbf{q}}[e^{-i\mathbf{k}\cdot\mathbf{\Psi}(\mathbf{q})} - 1]$ ，展开到二阶是 $\hat{\delta}_E^{(2)} = -ik_i \hat{\Psi}_i^{(2)} - \frac{1}{2}k_i k_j \widehat{\Psi_i^{(1)} \Psi_j^{(1)}}$ ，第二项（一阶位移改变了质量元的间距）在 $\vartheta^{(2)}$ 里没有。两项合起来就是 Eulerian 微扰论的 F_2 核，它在 $\mathbf{k} \rightarrow 0$ ($\mathbf{p}$ 固定) 时也是 $O(k^2)$ ，所以真实密度的 $\eta\eta$ 部分同样有 k^4 压低，但那是另一个计算。代码里的“散度谱”就是 ϑ ；粒子沉积得到的密度谱是另一个诊断量。

用 **Fourier 核再验一遍**。 K 的分子分母： $k_1^2 k_2^2 - (\mathbf{k}_1 \cdot \mathbf{k}_2)^2 = |\mathbf{k}_1 \times \mathbf{k}_2|^2$ ，而 $\mathbf{k}_2 = \mathbf{k} - \mathbf{k}_1$ 给 $\mathbf{k}_1 \times \mathbf{k}_2 = \mathbf{k}_1 \times \mathbf{k}$ ，所以

$$K(\mathbf{k}_1, \mathbf{k} - \mathbf{k}_1) = \frac{k_1^2 k_2^2 \sin^2 \theta_1}{k_1^2 k_2^2} = \frac{k^2 (1 - \mu_1^2)}{|\mathbf{k} - \mathbf{k}_1|^2}, \quad \mu_1 = \hat{\mathbf{k}} \cdot \hat{\mathbf{k}}_1, \quad (30)$$

一个精确恒等式。 $\eta\eta$ 项里 $|\mathbf{k} - \mathbf{k}_1| \geq k_{\text{Ny},c}$ ，所以 $\hat{S}_{\eta\eta} = k^2 \times (\text{方差与 } k \text{ 无关的量})$ ，和应力张量的结论一致。 $1 - \mu_1^2$ 的角度依赖就是 $\hat{k}_i \hat{k}_j \hat{T}_{ij}$ 里的各向异性。

自己算：(1) 从 (25) 出发在 *Fourier* 空间展开 $-k_i k_j \hat{T}_{ij}$ ，用 $\mathbf{k} = \mathbf{k}_1 + \mathbf{k}_2$ 化简，证明它等于 (20)。(2) 用 $\epsilon = k/k_1$ 展开 $(1 - \epsilon\mu)^2 / (1 - 2\epsilon\mu + \epsilon^2)$ 得到 (30) 的另一种推法。

离散性的 caveat。(22) 的修正项里 $S[\delta_L]$ 的抵消假设粗模拟没有 aliasing 地算出了二次项。网格代码在自己的网格上算乘积，两个接近 $k_{\text{Ny},c}$ 的模式相乘的支撑到 $2k_{\text{Ny},c}$ ，按 (5) 折回低 k ，而核是在大波数处取值的，没有 k^2 压低。真实 N-body 有自己的版本 (PM 网格 aliasing、力软化、时间步)。经验上它是一个幅度很小的白噪底，Phase 0 的面板 (a) 在真实 64/128/256/512 上量的就是它。

3.4 长短波耦合：细节只通过粗场的 deformation tensor 进来

(21) 的交叉项在实空间是逐点乘积。定义 deformation tensor $D_{ij} := \partial_i \Psi_j$ ，一阶时 $D_{ij}^{(1)} = -\phi_{,ij}$ ， $\text{tr } D^{(1)} = -\delta$ 。于是

$$B(\delta_L, \eta)(\mathbf{q}) = \text{tr } D^L(\mathbf{q}) \text{tr } D^\eta(\mathbf{q}) - D_{ij}^L(\mathbf{q}) D_{ij}^\eta(\mathbf{q}). \quad (31)$$

把 D^L 分成迹和无迹部分， $D_{ij}^L = -\frac{1}{3}\delta_L \delta_{ij} + \tau_{ij}^L$ ：

$$B = -\frac{2}{3}\delta_L \text{tr } D^\eta - \tau_{ij}^L D_{ij}^\eta. \quad (32)$$

第一项：局部过密区里小尺度模式长得更快，就是 separate-universe 的图像；第二项：潮汐场 τ^L 和小尺度形变的耦合，就是 anisotropic separate-universe 模拟测的响应。要点有两个。一是**局域**：粗场在 $\mathbf{q}$ 点的 D_{ij} 决定 $\mathbf{q}$ 点的源，非局域只来自后面那个 $\nabla\nabla^{-2}$ 的势求解。二是**只通过导数**：粗场加一个常数位移（整体平移）不改变任何东西。

所以网络的输入不是 Ψ_c ，而是 $D_{ij}(P\Psi_c)$ 的九个分量（无量纲、平移不变），外加以 h_f 为单位的残差。

4 给定粗场，细场是什么分布

记 $\mathcal{S}_\ell$ 为第 ℓ 级模拟代码从线性初条件到输出 $(\Psi_\ell, \mathbf{v}_\ell)$ 的映射，它是确定性的。记 C 为我们实际拿来作条件的那个粗输出。如果 C 决定 δ_c （比如 C 是完整的相空间输出 $(\Psi_c, \mathbf{v}_c)$ ，而且 $\mathcal{S}_c$ 可逆，这是初条件重建那一行工作的前提），那么给定 C 就等于给定 δ_c ，而

$$\Psi_f = \mathcal{S}_f[\delta_c + \eta], \quad \eta \sim \text{高斯, 与 } \delta_c \text{ 独立.} \quad (33)$$

用你熟悉的语言： $p(\Psi_f | C)$ 是一个已知高斯分布（ $7N^3$ 个标量自由度）在映射 $\eta \mapsto \mathcal{S}_f[\delta_c + \eta]$ 下的 push-forward。不假设 C 决定 δ_c 时，正确的写法是一个混合：

$$p(\Psi_f \in A | C) = \iint \mathbb{1}_A(\mathcal{S}_f[\delta_c + \eta]) \gamma(d\eta) p(d\delta_c | C), \quad (34)$$

γ 是 octave 的高斯分布， $p(\delta_c | C)$ 是给定 C 后粗初条件还剩多少不确定。

这个区别不是吹毛求疵，因为模型实际用的状态是一路缩减的： $(\Psi_c, \mathbf{v}_c) \rightarrow \Psi_c \rightarrow \mathcal{P}_W \Psi_c \rightarrow$ 网络有限感受野看到的一小块 $D_{ij}(P\Psi_c)$ 。完整映射可逆，不代表这些缩减后的观测还能反推出 δ_c 。诚实的描述就是 (34)，只有理想情形它才退化成单个 push-forward。两个后果。一是一个 $2\times$ 步骤要提供的随机性是 octave 加上缩减条件没能定下来的那部分 δ_c ，只有前者有干净的高斯形式。二是用球窗时被丢掉的角落模式 χ 属于 δ_c ，保留的场对它有信息，按先验重新采样是近似（第 1.4 节）；用立方体没有这个问题。

再往下一级， $\Psi_{\ell+1}$ 决定 $\delta_{\ell+1} \supset \delta_\ell$ 时， $p(\Psi_{\ell+2} | \Psi_{\ell+1}, \Psi_\ell) = p(\Psi_{\ell+2} | \Psi_{\ell+1})$ ：完整状态的逐级链是精确的 Markov 链，一步步乘起来就是 $p(\Psi_L | \Psi_0)$ 。缩减状态（投影场、patch）上的链只有在缩减是充分统计量时才是 Markov 的，否则前几级带着当前状态已经丢掉的信息，链上用的单步条件分布是一个建模近似。这也是保留立方体窗、并且最终把速度场放进状态的理由之一。

两个后果。随机性有物理身份、维数已知：模型的噪声就取 η ，训练时用真实的 η （Paper IV 的设定，逐级化），采样时换随机的 η （生成模型）。在理想条件下（ C 决定 δ_c ） Ψ_f 是 (C, η) 的确定性函数：一个完美的回归模型喂真实 η 就精确，喂随机 η 就是合法的生成模型。混沌在精确算术下不改变这一点（一个初条件只有一个结果）；它改变的是有限容量、有限感受野、有限数据的模型实际能用上 (δ_c, η) 里的多少信息，以及真实代码里舍入误差被放大得多快。下一节的 flow matching 的写法保证了它在生成模式下的正确性不依赖于回归是否精确。

5 Flow matching：从一个能手算的例子开始

5.1 一维高斯例子

先把所有场论忘掉，看两个一维高斯变量。 $x_0 \sim \mathcal{N}(0, \sigma_0^2)$ ， $x_1 \sim \mathcal{N}(0, \sigma_1^2)$ ，相关系数 ρ （ $\rho = 0$ 是独立配对， $\rho > 0$ 是“物理配对”）。目标：找一个变换把 x_0 的样本变成 x_1 分布的样本。

Flow matching 的做法：连一条直线 $x_t = (1-t)x_0 + tx_1$ ，沿线速度 $x_1 - x_0$ ，定义

$$u_t(x) := \mathbb{E}[x_1 - x_0 \mid x_t = x]. \quad (35)$$

高斯情形条件期望是线性回归: $u_t(x) = \frac{\text{Cov}(x_1 - x_0, x_t)}{\text{Var}(x_t)} x_0$ 。算两个量:

$$s_t^2 := \text{Var}(x_t) = (1-t)^2 \sigma_0^2 + t^2 \sigma_1^2 + 2t(1-t)\rho\sigma_0\sigma_1, \quad (36)$$

$$\text{Cov}(x_1 - x_0, x_t) = t\sigma_1^2 - (1-t)\sigma_0^2 + (1-2t)\rho\sigma_0\sigma_1 = \frac{1}{2} \frac{ds_t^2}{dt}. \quad (37)$$

(最后一个等号请自己验证。) 所以 $u_t(x) = \frac{\dot{s}_t}{s_t} x$, 常微分方程 $\dot{x} = u_t(x)$ 的解是

$$x(t) = x(0) \frac{s_t}{s_0} \implies x(1) = x_0 \frac{\sigma_1}{\sigma_0}. \quad (38)$$

从 $x_0 \sim \mathcal{N}(0, \sigma_0^2)$ 出发, 终点的方差恰好是 σ_1^2 : 变换对了。注意三件事。第一, ρ 从最后的答案里消失了: **coupling 不影响生成出来的分布**, 这是下一小节一般定理的一维版本。第二, ρ 影响的是训练难度: 网络要拟合的目标 $x_1 - x_0$ 的方差是 $\sigma_0^2 + \sigma_1^2 - 2\rho\sigma_0\sigma_1$, ρ 越大目标越“确定”, 路径越短。第三, 如果只走一步 Euler, $\hat{x}_1 = x_0 + u_0(x_0) = \mathbb{E}[x_1 | x_0] = \rho \frac{\sigma_1}{\sigma_0} x_0$, 它的方差是 $\rho^2 \sigma_1^2$ 而不是 σ_1^2 : 一步等于给定 x_0 的条件均值, x_0 没定下来的那 $(1-\rho^2)$ 的方差就丢了。注意这是 $\rho < 1$ 、即 x_0 不能完全决定 x_1 时的说法; $\rho = 1$ 时一步就精确。这个区别在第 5.5 节很要紧。

5.2 一般情形: 为什么条件期望就够了

现在 x_0, x_1 是高维的 (细网格上的场), 联合分布 π 任意, 只要求边缘分布正确。 p_t 记 x_t 的分布, $u_t(x) = \mathbb{E}_\pi[x_1 - x_0 | x_t = x]$ 。取任意光滑试探函数 φ , 算 $\mathbb{E}\varphi(x_t)$ 对 t 的导数:

$$\frac{d}{dt} \mathbb{E}\varphi(x_t) = \mathbb{E}[\nabla\varphi(x_t) \cdot (x_1 - x_0)] \stackrel{\text{tower}}{=} \mathbb{E}[\nabla\varphi(x_t) \cdot \mathbb{E}[x_1 - x_0 | x_t]] = \int \nabla\varphi(x) \cdot u_t(x) p_t(x) dx. \quad (39)$$

中间那一步就是 tower property: 先对给定 x_t 取条件期望, 再对 x_t 平均。左边是 $\int \varphi \partial_t p_t$, 右边分部积分是 $-\int \varphi \nabla \cdot (p_t u_t)$ 。对所有 φ 成立, 所以

$$\boxed{\partial_t p_t + \nabla \cdot (p_t u_t) = 0} \quad (40)$$

这是连续性方程 (Liouville): 一团按速度场 u_t 运动的“流体”, 密度就这样演化。反过来, 如果把一堆粒子从 $x_0 \sim p_0$ 出发按 $\dot{x} = u_t(x)$ 推动, 它们的密度满足同一个方程、同一个初值, 所以在 $t = 1$ 时的分布就是 p_1 , 也就是 x_1 的分布。整个论证里 π 只通过 u_t 出现, 而 u_t 是对同一个 x_t 的所有来源取平均——所以不同的 coupling 会给出不同的直线、不同的 u_t , 但同样正确的终点分布。

5.3 训练目标

网络 $v_\theta(x, t)$ 拟合 u_t 。用最小二乘:

$$\mathcal{L} = \mathbb{E}_{t, \pi} \|v_\theta(x_t, t) - (x_1 - x_0)\|^2 = \mathbb{E}_t \mathbb{E}_{x_t} \|v_\theta(x_t, t) - u_t(x_t)\|^2 + \mathbb{E}_t \mathbb{E}[\text{Var}(x_1 - x_0 | x_t)]. \quad (41)$$

第二步是“均方误差 = 偏差平方 + 不可约方差”, 交叉项按 tower property 为零。第二项与 θ 无关, 所以最小值在 $v_\theta = u_t$ 。物理配对让第二项变小 (目标更可预测), 这就是它帮助训练的机制。

5.4 我们的 x_0 、 x_1 和 coupling

回到场。全部放到细网格上、以 h_f 为单位：

$$x_0 = P\Psi_c + \underbrace{D \frac{i\mathbf{k}}{k^2} \hat{\eta}}_{\text{octave 的线性理论}}, \quad x_1 = \Psi_f. \quad (42)$$

物理配对： $x_1 = \mathcal{S}_f[\delta_c + \eta]$ 和 x_0 用同一个 η ；独立配对： x_0 里换成另一个独立的 η' 。两者边缘分布相同（ x_0 的分布只依赖 η 的分布），所以按上一小节都合法。把 Ψ_f 写成 $P\Psi_c + D i\mathbf{k}\hat{\eta}/k^2 + \rho$ ， ρ 是二阶及以上的部分（(22) 加高阶），则

$$\mathbb{E}\|x_1 - x_0\|_{\text{phys}}^2 = \mathbb{E}\|\rho\|^2, \quad \mathbb{E}\|x_1 - x_0\|_{\text{indep}}^2 = \mathbb{E}\|\rho\|^2 + 2\mathbb{E}\left\|D \frac{i\mathbf{k}}{k^2} \hat{\eta}\right\|^2 + 2\mathbb{E}\langle \rho, D \frac{i\mathbf{k}}{k^2} \hat{\eta} \rangle, \quad (43)$$

最后一项在二阶为零（ $\rho^{(2)}$ 是 η 的二次型，和 η 的一次项的期望是三阶矩，Wick 给零）。独立配对让网络多背两倍的线性 octave 方差——它已经知道的东西。物理配对下 $x_1 - x_0$ 在一阶为零，单流区很小，只在 halo 内部（ $\eta \mapsto \Psi_f$ 混沌的地方）才大。玩具模型里光 x_0 就已经和真值有 $r \approx 0.92$ 。

网络实际看到的是 $x_t - P\Psi_c$ （相对插值粗场的残差）和 $D_{ij}(P\Psi_c)$ ，目标 $x_1 - x_0$ 。三者对所有场加同一个常数都不变，所以学出来的映射天然平移不变。

5.5 一步等于回归： $P_{\text{pred}}/P_{\text{true}} = r^2$ ，以及它相对什么信息成立

一维例子已经看到一步 Euler 给出条件均值 $\mathbb{E}[x_1 | x_0]$ 。先说清楚它相对什么信息成立。一般地，记 $\mathcal{I}$ 为预测时手上的信息，对任意 Fourier 模式 $\hat{x}_1(\mathbf{k})$ ，全方差公式

$$\mathbb{E}|\hat{x}_1|^2 = \mathbb{E}|\mathbb{E}[\hat{x}_1 | \mathcal{I}]|^2 + \mathbb{E}[\text{Var}(\hat{x}_1 | \mathcal{I})] \quad (44)$$

说条件均值的功率比真值少了恰好条件方差。再算它和真值的互功率： $\mathbb{E}[\hat{x}_1 \overline{\mathbb{E}[\hat{x}_1 | \mathcal{I}]}]$ ，先对给定 $\mathcal{I}$ 取条件期望（tower）， $\hat{x}_1 \rightarrow \mathbb{E}[\hat{x}_1 | \mathcal{I}]$ ，得到 $\mathbb{E}|\mathbb{E}[\hat{x}_1 | \mathcal{I}]|^2$ ，即互功率等于条件均值自己的功率。于是

$$r = \frac{P_{\text{cross}}}{\sqrt{P_{\text{pred}}P_{\text{true}}}} = \sqrt{\frac{P_{\text{pred}}}{P_{\text{true}}}} \implies \boxed{\text{给定 } \mathcal{I} \text{ 的条件均值: } \frac{P_{\text{pred}}}{P_{\text{true}}} = r^2; \text{ 生成模型: } \frac{P_{\text{pred}}}{P_{\text{true}}} = 1} \quad (45)$$

一维例子里 $r = \rho$ 、功率比 ρ^2 ，正是这个。

关键在 $\mathcal{I}$ 是什么。用物理配对时， $x_0 - P\Psi_c = D i\mathbf{k}\hat{\eta}/k^2$ 就是线性 octave， $\eta = -D^{-1}\nabla \cdot (x_0 - P\Psi_c)$ 可以精确反推；如果 C 又决定 δ_c ，那么 $x_1 = \mathcal{S}_f[\delta_c + \eta]$ 是 (x_0, C) 的确定性函数， $\text{Var}(x_1 | x_0, C) = 0$ 。这时理想的一步回归是精确的，理想的 flow 也是精确的，混沌不改变这一点。所以**不能说**“一步回归必然丢功率”。 $P/P = r^2$ 这条线描述的是信息不完整的情形：只给粗场不给 octave、独立配对、只看一个 patch、网络容量有限。真正的对比是：**不带 octave 的回归**（或独立配对下的回归）会塌缩到 $\mathbb{E}[x_1 | C]$ ，落在 $P/P = r^2$ 上；而随机性就是 octave 的生成模型落在 $P/P = 1$ 上。物理配对下两种目标原则上都精确，flow 的好处是经验性的（每个 t 上一个更容易的回归、多步迭代细化），不是方差论证。

顺便更正一个容易说错的句子：确定性 ODE 不会”把被平均掉的残差重新加回来”。 u_t 本身就是条件均值，样本的全部随机性来自 x_0 ，多步积分只是把它运输得更准。

再看玩具数据。参考的 $16 \rightarrow 32$ 模型一步 Euler 给出 $r = 0.993$ 、功率比 0.959，而一个以该 r 为最优的条件均值应有 $r^2 = 0.986$ ：一步模型并不是最优回归，差的那部分是模型和优化的缺陷；八步 Heun 把功率比提到 0.993，应当解读为多步参数化把同一个映射拟合得更好，而且要用相同条件下直接训练的回归 baseline 来区分。采样 octave 的生成模式功率比 1.02、 $r \approx 0$ ，符合生成模型那条线。

5.6 采样、步数、以及怎么采 octave

采样就是从 $X_0 = x_0$ 出发用 Heun（二阶 Runge-Kutta）积分 $\dot{X} = v_\theta(X, t)$ 到 $t = 1$ 。因为路径短而直，步数很少：1, 2, 8 步给功率比 0.959, 0.978, 0.993，按第 5.5 节的讨论，这衡量的是多步参数化对映射的拟合程度，不是方差的恢复。逐 octave 生成的好处（Guth 等 2022 的论点）是每一级的任务都是”相对输入生成下一个 octave”，所以步数不随总分辨率增长。

采 η 时不需要外部的线性功率谱：从训练集的初条件位移算 $\hat{\delta}^{(1)} = -i\mathbf{k} \cdot \hat{\Psi}^{(1)}$ ，测各向同性的 $P_\delta(k)$ ，用它合成一个高斯 $\hat{\delta}$ （只在 W 之外的模式上；用立方体时这正好是 octave，用球时还包括角落模式，受第 1.4 节那个 caveat 的限制），再用 (14) 变成位移。这样位移自动无旋。直接对三个分量各采一个高斯是错的，那样的场有旋度，线性阶就不对。

6 无量纲化与自相似

位移有长度量纲，大尺度 bulk flow 以 h_ℓ 为单位会随 ℓ 增大而无界； D_{ij} 无量纲、平移不变、在已分辨尺度上的统计不依赖网格。细节以格距为单位的幅度： $P_\Psi \propto P_{\text{lin}}/k^2$ ，一个 octave 的位移方差 $\sigma_{\Psi, \ell}^2 \propto \int k^2 dk k^{n-2} \propto k_\ell^{n+1}$ ，所以 $\sigma_{\Psi, \ell}/h_\ell \propto k_\ell^{(n+3)/2}$ ， $n > -3$ 时随层级缓慢增大，有界。一个共享权重的网络因此在每一级看到同类输入，只需再喂一个”这一级多非线性”的标量。

尺度无关宇宙（ $P \propto k^n$ ，EdS）里这是严格的。 $\sigma^2(R, a) \propto a^2 R^{-(n+3)}$ ，令 $\sigma(R_{\text{NL}}, a) = 1$ 得 $R_{\text{NL}} \propto a^{2/(n+3)}$ ；所有无量纲统计只通过 $r/R_{\text{NL}}(a)$ 依赖长度。第 $\ell + 1$ 级在 a 时刻的无量纲状态是 $h_{\ell+1}/R_{\text{NL}}(a)$ ，要它等于第 ℓ 级在 a' 时刻的 $h_\ell/R_{\text{NL}}(a')$ ：

$$R_{\text{NL}}(a') = 2R_{\text{NL}}(a) \iff a' = 2^{(n+3)/2}a \quad (n = -2 : a' = \sqrt{2}a). \quad (46)$$

往下走一级等于等到 R_{NL} 翻倍。有限盒子只在最长波长上破坏它，而算子是局域的，所以够用。 ΛCDM 没有严格自相似，就把算子条件化在 $s_\ell = (\sigma(h_\ell, z), n_{\text{eff}}(k_\ell), f(z))$ 上，假设 $2\times$ 算子只通过这三个数依赖层级、红移和宇宙学——和 halo mass function 对 ν 的普适性是同一类假设，可以在真实序列上用匹配 σ 的两个 transition 检验。

7 评估指标

所有谱都是三个分量求和后的球壳平均, 分别在粗带 (W) 和 octave 带 ($1 - W$) 里算。互相关系数 $r(k) = P_{ab}/\sqrt{P_{aa}P_{bb}}$ 在 emulator 模式下衡量确定性, $1 - r^2$ 是生成模型必须提供的那部分功率。功率比 P_{aa}/P_{bb} 在生成模式下必须是 1; $(r, P_{aa}/P_{bb})$ 这一对数把模型定位在回归线 $P/P = r^2$ 和生成线 $P/P = 1$ 之间。粗带的相对修正误差 $(P_{aa} + P_{bb} - 2P_{ab})/P_{bb}$ 衡量这一步把粗模拟修得多好; 生成模式下它比 emulator 模式大, 因为 (25) 里的 $\hat{T}_{ij}^{\eta\eta}$ 随 octave 的实现变化。Wiener 传递函数 $T(k) = P_{cf}/P_{ff}$ 是让 $\mathbb{E}|T\Psi_f - \Psi_c|^2$ 最小的各向同性线性滤波 (逐模式对 T 求极小, 二次函数), 即”真实低分辨率模拟最像的那种 coarse-graining”, 用来决定 α 放在哪。

8 哪些是推出来的, 哪些是假设, 哪些要靠数据

推出来的: 第 1 节的采样与投影恒等式; 线性阶 $\varepsilon^{(1)} = 0$ 、细节独立高斯; (22) (含细节里粗模式的谐波项)、(25) 与 $\eta\eta$ 项的 k^2/k^4 定律 (Wick 形式); (31) 的局域性; 混合形式的 push-forward (34) 与完整链的 Markov 性; 连续性方程与 coupling 无关性; 损失的极小元; 相对信息集 $\mathcal{I}$ 的 $P/P = r^2$; 尺度无关的层级-时间对应。

要记住的理想化: push-forward 只在条件决定 δ_c 时退化为单个映射, 实际用的缩减状态 (投影场、patch、有限网络) 让它变成混合、让缩减链只近似 Markov; 用球窗时角落模式被重新采样而保留场对它有信息 (立方体窗没有这个问题); k^2/k^4 是理想二阶 $\eta\eta$ 项的结果, 混合项至少同样陡, 高阶和离散性误差不保证同一指数; ”散度谱” 是位移的散度, 不是 Eulerian 密度。

假设、要在真实 64/128/256/512 上测: 真实低分辨率模拟的离散性白噪底足够小 (Phase 0 面板 (a)); 给定局部 D_{ij} 后细节在单流区近高斯、在多流区仍可处理 (面板 (c)); s_ℓ 的普适性足够好 (匹配 σ 的比较)。玩具实验用的是 2LPT, 没有壳层交叉, 对多流区什么都说明不了。

相对第一版的修改 (根据一份外部审阅): (19) 实空间形式的符号; (22) 中 $d^{(2)}$ 漏掉的 $S[\delta_L]$ 项; 散度与密度的区分和 k^4 的 Wick 形式; 条件分布的混合形式与 Markov 性的适用范围; 删去”一步回归必然丢功率”和”多步 flow 把方差加回来”两个说法; 把立方体窗定为理论默认。

公式与代码的对应

- (7) 的因子与相位: `Grid.phase_restrict_spectral_prolong_spectral(phase0_octaves.py)`, `Scaffold.prolong(octave_flow_toy.py)`。
- W : `sphere_window / cube_window`; 细节 $(1 - W)$: `Scaffold.band` 的 "high" 分支。
- ε 、 $T(k)$ 、 $r(k)$: `analyse_transition` 的 (a) 部分; 线性 octave 与 d 的比较: (b) 部分。
- D_{ij} 的不变量与分箱: `coarse_invariants_conditional_stats`。
- 去 aliasing 的 2LPT 层级 (验证 k^2): `make_selftest` 的 `dealias=True`; aliased 版本模拟真实低分辨率模拟的离散性。

- x_0 、 x_1 与损失: `Batcher.make` 和训练循环; u_t 的积分: `sample_flow`。
- 无旋 octave 采样: `sample_linear_octave`; D_{ij} 输入: `Scaffold.gradients`。